

AgroVision

Deteccion de condiciones visibles en hojas de uva con YOLOv8

Prueba de concepto - Informe Ejecutivo

May 2026

Documento sin código fuente. Enfocado en solución de negocio.

Entregable: proyecto_yolo_uva/informe_ejecutivo.pdf

1. Resumen Ejecutivo

Se desarrollo una prueba de concepto basada en vision por computadora para detectar condiciones visibles en hojas de uva utilizando YOLOv8 (Ultralytics). El modelo clasifica y localiza cuatro tipos de condiciones: BlackRot, Esca, Healthy y LeafBlight, generando alertas operativas para priorizar revisiones tecnicas en campo.

Los resultados obtenidos son altamente prometedores para una prueba de concepto: precision media (mAP50) de 0.964, precision de 0.971 y recall de 0.923. Esto demuestra que es viable construir una solucion de apoyo a la toma de decisiones utilizando modelos preentrenados y transfer learning, incluso con un dataset moderado.

El sistema no solo detecta condiciones en las hojas, sino que transforma cada prediccion en una recomendacion operativa concreta: revision prioritaria, revision manual, monitoreo o sin alerta. Esto permite integrar la IA directamente en el flujo de trabajo del equipo tecnico y agronomico.

0.964

mAP50

0.906

mAP50-95

0.971

Precision

0.923

Recall

2. Problema de Negocio

La empresa realiza inspecciones visuales manuales para evaluar la calidad y condiciones de cultivos. Este proceso enfrenta desafios importantes:

- Dependencia de la experiencia del personal para identificar condiciones
- Alto volumen de trabajo que puede llevar a omisiones o errores
- Variabilidad en las condiciones de observacion (iluminacion, angulo, distancia)
- Dificultad para priorizar objetivamente los casos que requieren atencion
- Falta de trazabilidad digital de las inspecciones realizadas

El objetivo de negocio es contar con una herramienta que apoye al equipo tecnico y agronomico en la deteccion temprana de condiciones anomalas, permitiendo priorizar revisiones, reducir inspecciones innecesarias y generar registros trazables de cada evaluacion.

3. Solucion Propuesta

Se propone un sistema de deteccion de objetos basado en YOLOv8 (You Only Look Once) que analiza imagenes de hojas de uva y detecta condiciones visibles mediante bounding boxes. El sistema consta de tres componentes principales:

3.1 Modelo de deteccion

YOLOv8n (nano) preentrenado en COCO, ajustado mediante transfer learning con el dataset GRAPE Leaf Diseases. El modelo procesa cada imagen y genera bounding boxes con la clase detectada y un nivel de confianza asociado.

3.2 Motor de reglas de alerta

Las predicciones del modelo se transforman en alertas operativas mediante reglas de negocio. Cada deteccion se clasifica en uno de cuatro niveles de prioridad segun su confianza y tipo de condicion detectada.

3.3 Reportes y trazabilidad


El sistema genera reportes estructurados (CSV/JSON) con todas las predicciones, su nivel de alerta y la necesidad de revision humana, permitiendo auditoria y trazabilidad completa.

4. Dataset

Se utilizó el dataset público GRAPE Leaf Diseases de Kaggle, que contiene imágenes de hojas de uva con anotaciones en formato YOLO (bounding boxes).

Clase	Etiqueta	Cantidad	Proporción
BlackRot	GRBR	1,147	26.0%
Esca	GRES	1,383	31.3%
Healthy	GRHE	643	14.6%
LeafBlight	GRLB	1,242	28.1%

Total: 4,195 imágenes (3,358 train / 837 val) con 4,415 bounding boxes. La clase Healthy está subrepresentada (14.6%), lo que puede generar sesgo en las predicciones hacia clases con más ejemplos.



Distribucion de clases en el dataset

5. Metodologia

5.1 Enfoque tecnico

Se opto por YOLOv8n (nano) con transfer learning por las siguientes razones:

- Modelo preentrenado en COCO: aprovecha características visuales generales
- Arquitectura ligera: reduce riesgo de sobreajuste con dataset moderado
- Entrenamiento rapido: permite iterar y validar hipotesis rapidamente
- Facil despliegue: compatible con entornos de produccion y edge computing

5.2 Entrenamiento

Parametro	Valor
Modelo base	yolov8n.pt (COCO pre-trained)
Epocas	30 (early stopping en epoca 7)
Tamano imagen	640x640 px
Batch	8
Optimizador	Adam (auto)
Aumentacion	Flip HR, brillo/contraste, rotaciones
Semilla	42
Dispositivo	CPU

El entrenamiento se detuvo en la epoca 7 por early stopping (paciencia de 10 epocas sin mejora). Esto indica que el modelo convergio rapidamente gracias al transfer learning.

5.3 Evaluacion por umbrales

Se evaluaron cuatro umbrales de confianza para seleccionar el punto de operacion optimo:

Umbral	Precision	Recall	mAP50	mAP50-95
0.25	0.974	0.923	0.948	0.897
0.40	0.974	0.923	0.941	0.891
0.50	0.974	0.923	0.934	0.885
0.70	0.984	0.902	0.896	0.860

El umbral de 0.50 ofrece el mejor equilibrio entre precision y recall para una prueba de concepto, manteniendo alta deteccion sin sacrificar exactitud.

6. Resultados

El modelo alcanzo metricas sobresalientes para una prueba de concepto:

Metrica	Valor	Interpretacion
mAP50	0.964	Deteccion y localizacion de alta calidad
mAP50-95	0.906	Rendimiento consistente en distintos IoU
Precision	0.971	Cuando alerta, acierta el 97.1% de las veces
Recall	0.923	Detecta el 92.3% de las condiciones presentes

Interpretacion operativa: de cada 100 condiciones presentes en las imagenes, el sistema detecta correctamente 92. Y de cada 100 alertas generadas, 97 son correctas. Esto indica que el sistema es confiable como herramienta de apoyo a la priorizacion, con una tasa baja de falsos positivos.

Los falsos negativos (8% de condiciones no detectadas) pueden deberse a oclusion, iluminacion desfavorable o tamano pequeno de la region afectada. Estos casos deben derivarse a revision manual.

7. Reglas de Alerta

Cada prediccion del modelo se transforma en una accion operativa mediante reglas de negocio disenadas con el equipo tecnico:

Nivel	Confianza	Accion operativa
Alta prioridad	>= 70%	Notificacion inmediata al equipo tecnico
Revision manual	>= 40%	Agendar revision en el dia
Monitoreo	< 40%	Guardar evidencia, revisar por muestreo semanal
Sin alerta	Sin detecciones	No requiere accion

Ejemplo de aplicacion: si el modelo detecta Esca con 82% de confianza, se genera una alerta de alta prioridad. Si detecta LeafBlight con 35%, se registra en monitoreo para revision por muestreo.

8. Integración en Operación

8.1 Flujo operativo

1. Captura de imagen en campo (dispositivo móvil o cámara)
2. Carga automática al sistema (carpetas compartidas o API)
3. Inferencia con modelo YOLO
4. Generación de predicciones con bounding boxes y confianza
5. Aplicación de reglas de alerta (priorización automática)
6. Visualización en dashboard con imágenes anotadas
7. Validación humana del equipo técnico
8. Registro del resultado real (confirmación o corrección)
9. Retroalimentación para reentrenamiento del modelo

8.2 Arquitectura sugerida

Para producción se recomienda: API REST con FastAPI para inferencia, dashboard en Streamlit para visualización, almacenamiento en base de datos relacional y bucket de imágenes. El modelo se actualiza periódicamente con datos validados por el equipo técnico.

8.3 Usuarios involucrados

- Técnico de campo: captura imágenes y valida predicciones
- Equipo agronómico: revisa alertas de alta prioridad
- Supervisor de calidad: monitorea dashboard y tendencias
- Equipo de datos: gestiona reentrenamiento y mejora del modelo

9. Conclusiones

La prueba de concepto demuestra que es viable construir una solución de visión por computadora para detectar condiciones en hojas de uva utilizando YOLOv8 con transfer learning. Las métricas obtenidas (mAP50 = 0.964) son altamente satisfactorias para una fase inicial.

9.1 Próximos pasos

- Recolectar 500-1000 imágenes propias con condiciones reales de campo
- Validar el sistema con el equipo técnico y agronómico
- Implementar API de inferencia con FastAPI
- Desarrollar dashboard en Streamlit para visualización de alertas
- Establecer pipeline de reentrenamiento continuo con datos validados

9.2 Limitaciones identificadas

- Dataset moderado (4,195 imágenes): riesgo de sobreajuste
- Clase Healthy subrepresentada (14.6%): posible sesgo
- Dataset de Kaggle: condiciones controladas, no equivalentes a campo real
- Sin validación con usuarios finales ni medición de impacto económico

Se recomienda avanzar a una fase de validación en campo con datos propios de la empresa antes de considerar un despliegue productivo.